

阿布扎比土地利用三模型模拟与优化完整报告

GeoSOS-FLUS、GWM Geospatial Kernel 与 Paper58 的统一真实数据实验

GWM / Geospatial Kernel 研究工作

2026-08-02

目录

章节	内容
执行摘要	实验回答了什么、主要结果与结论边界
1	研究对象：不是“整个世界”，而是一个有界城市世界
2	原始输入数据到底是什么
3	三个模型实际看到了什么
4	统一实验协议
5	历史模拟结果：2023 单步和 2024 两步开环
6	2025–2030 条件规划推演结果
7	三模型综合对比
8	这项工作证明了什么价值
9	数据和方法局限
10	从公共基准走向真实运营还缺什么数据
11	下一阶段应该怎样推进
12	可复现性与产物
13	最终结论

执行摘要

本报告回答一个具体问题：在阿布扎比城市这一有界空间内，使用同一批真实数据、同一网格、同一土地覆盖类别、同一需求动作和同一硬约束，传统 GeoSOS-FLUS、GWM Geospatial Kernel 和 Paper58 分别能够完成怎样的历史模拟和规划情景推演？

这次工作已经越过“概念设计”和“路线图”阶段，形成了真实可运行的三模型实验：

- 空间范围固定为 OpenStreetMap 城市关系 R4479763 对应的阿布扎比城市边界；
- 所有输入统一到 EPSG:32640、100 m 网格，城市共同有效域为 79,726 个像元，约 797.26 km²；
- 输入包括 2017–2024 Dynamic World 年度土地覆盖与质量、2017–2024 AlphaEarth 64 维年度嵌入、2017–2024 VIIRS 夜间灯光、Copernicus DEM、OSM 道路、ESA WorldCover 水体/湿地约束以及 OSM 公共代理约束；
- 历史实验从 2022 年起点开环推演 2023、2024，三个模型均运行随机种子 31、47、73；
- 规划实验从 2024 年起点，在紧凑增长、生态优先、外延增长三组条件需求下逐年推演到 2030；
- 共形成 18 张历史种子预测、6 张历史集成预测、162 张规划种子预测和 54 张规划集成预测；240 张发布栅格全部通过网格、类别、域外 no data 和硬约束审计。

主要结果如下。

问题	结果
2023 单步历史模拟谁最好？	Geospatial Kernel，三种子平均 change FoM 为 0.2004。
2024 两步开环历史模拟谁最好？	Paper58，三种子平均 change FoM 为 0.2778。
两个新模型是否优于 GeoSOS-FLUS？	在全有效域 change FoM 上，Geospatial Kernel 与 Paper58 在 2023、2024 均高于外部 GeoSOS-FLUS。
2030 规划代理指标谁最好？	当前冻结目标下，三个 Geospatial Kernel 情景均进入 Pareto 前沿；Paper58 和 FLUS 被支配。
是否已经证明能够预测阿布扎比真实未来？	没有。规划需求是条件压力测试，不是政策预测；公开约束也是代理数据。
当前最大科学风险是什么？	Dynamic World 年度标签波动明显：平均 54.97% 像元的年度最高概率低于 0.5，高置信度变化 FoM 对三个模型都很低。

因此，当前最稳妥的结论不是“Geospatial Kernel 已经预测了阿布扎比未来”，而是：

在一个边界、状态、动作、约束和评价器均被明确限定的城市土地覆盖世界中，Geospatial Kernel 已经表现出高于传统外部 FLUS 的历史条件分配能力，并在当前规划代理目标下给出了更紧凑、更邻近既有建设和主干路、且满足硬约束的空间方案。Paper58 则表现出更强的两步开环历史拟合能力，但其规划空间分配尚未优于显式 Geospatial Kernel。


1. 研究对象：不是“整个世界”，而是一个有界城市世界

本实验中的“世界”被严格限定为阿布扎比城市土地覆盖系统。它不试图同时模拟人口、产业、金融、全部交通、政策博弈和社会行为，而只回答以下有边界的问题：

1. 已知当前土地覆盖状态和目标类别总量时，模型把变化分配到哪些空间位置？
2. 模型能否在不读取测试期标签的情况下，从 2022 年状态递归推演 2023 和 2024？
3. 已知规划者给定的未来建成区和绿地需求时，不同模型会生成怎样的 2025–2030 空间布局？
4. 这些布局在生态占用、紧凑性、道路可达性、既有建成区邻近性和硬约束方面有何差异？

这里使用的六类数据是土地覆盖，而不是地籍意义上的住宅、商业、工业等土地用途。六类分别为：水体、木本植被、低矮植被、湿地、建成区和裸地。

阿布扎比三模型统一实验设计



公平性原则：模型只改变“如何分配空间”，不改变城市边界、网格、需求、约束和评价器。

图 1 阿布扎比三模型统一实验设计

图 1 展示了本实验的公平性原则：三个模型可以使用各自不同的空间建模机制，但不能改变城市边界、统一网格、需求动作、硬约束和评价器。

2. 原始输入数据到底是什么

2.1 数据源总表

下表区分了“外部原始产品”和“模型实际消费的统一输入”。统一到 100 m 只是建立共同计算网格，不意味着低分辨率产品因此产生了新的 100 m 细节。例如 VIIRS 的原生空间信息仍然约为 500 m。

数据	外部提供方/产品	原始时空情况	本地物化和统一方式	模型中的作用	主要局限
城市边界	OpenStreetMap , 经 Nominatim 获取 R4479763	2026-08-01 获取的矢量 Polygon	投影到 EPSG:32640 , 以像元中心落入边界为准栅格化	冻结城市空间范围	OSM 城市关系不等同于阿布扎比法定规划边界
年度土地覆盖	Google Dynamic World V1	Sentinel-2 驱动的 10 m 场景标签；2017-2024	每年对场景 argmax 标签取众数，再映射到六类并聚合到 100 m	显式状态、训练标签、历史评价标签	年际分类波动明显，不能把所有标签变化理解为真实人类行动
标签质量	Dynamic World 类别概率与场景数	与土地覆盖场景同步	年度平均最高类别概率和年度观测次数，100 m	只用于数据审计和预冻结敏感性评价，不向模型开放	概率不是严格校准后的变化真实性概率
遥感表征	Google AlphaEarth / Satellite Embedding V1 Annual	2017-2024 年度 64 维嵌入，产品名义 10 m	100 m 空间均值后，对每个像元做 L2 归一化	Paper58 潜状态；变化信号审计	64 个维度没有逐维物理语义，PCA 仅用于显示

数据	外部提供方/产品	原始时空情况	本地物化和统一方式	模型中的作用	主要局限
夜间灯光	NOAA VIIRS DNB Monthly V1	月度 avg_rad , 原生约 500 m	每年 12 个月均值，输出到 100 m 共同网格	人类活动强度代理	100 m 输出不代表新增了 100 m 的真实空间信息
地形	Copernicus DEM GLO30 2024.1	约 30 m DEM	DEM 聚合到 100 m；坡度在共同 100 m DEM 上有限差分计算	静态开发适宜性和约束驱动	阿布扎比大部分区域坡度小，区分力有限
水体与湿地约束	ESA WorldCover 2021 v200	10 m，类别 80、90、95	100 m 内任一源像元命中即形成水体/湿地代理约束	硬约束构造	单一年份产品，不能替代最新法定生态红线
道路与公共约束	Geofabrik GCC OSM PBF	2026-07-31 快照，矢量要素	提取道路、主干道、保护区、机场/港口代理并栅格化	道路距离驱动、公共代理硬约束	OSM 完整度不均；保护区和基础设施不是权威法定图层

本地清单记录了 34 个主要 Earth Engine 输入文件。清单内文件总大小为 156,546,478 字节，其中 AlphaEarth 8 个年度文件占主体；另保存了 251,917,202 字节的 Geofabrik GCC PBF 快照及其派生栅格。所有关键输入均记录 SHA-256 哈希。

2.2 统一空间范围与网格

属性	冻结值
边界名称	Abu Dhabi / OSM relation 4479763
WGS84 包围盒	54.2971553–54.7659108°E，24.2810331–24.601854°N
投影坐标系	EPSG:32640
空间分辨率	100 m
栅格宽 × 高	475 × 360
包围盒总像元	171,000
城市 mask 像元	79,775
2017–2024 共同有效像元	79,726
矢量边界面积	797.63 km²
栅格化城市面积	797.75 km²

Dynamic World 九类到本实验六类的映射如下。

Dynamic World 原类别	本实验类别	处理
water	水体 (1)	保留
trees	木本植被 (2)	保留
grass	低矮植被 (3)	合并
flooded vegetation	湿地 (4)	保留
crops	低矮植被 (3)	合并
shrub and scrub	低矮植被 (3)	合并
built	建成区 (5)	保留
bare	裸地 (6)	保留
snow and ice	nodata (0)	排除

2.3 2017–2024 土地覆盖状态




图 2 2017 和 2024 土地覆盖、变化位置与年度面积轨迹


图 2 直接来自年度 GeoTIFF。2017–2024 共同有效域中有 9,682 个像元至少发生过标签差异，占 12.1%。年度面积轨迹显示：

- 裸地始终是面积最大的类别，但由 2017 年约 534.63 km² 下降到 2024 年约 457.64 km²；
- 建成区标签由 2017 年约 91.05 km² 增加到 2024 年约 155.98 km²；
- 水体在年度产品中约为 148.51–160.62 km²；
- 木本植被、低矮植被和湿地面积较小，因此宏平均指标和变化指标比单纯总体准确率更重要。

这里必须注意：这些面积是年度遥感分类产品的面积，不是阿布扎比官方土地台账。尤其是水体、滩涂、浅水和湿地边缘容易受成像日期与分类边界影响。

2.4 地形、夜光、道路和 AlphaEarth 表征

模型实际使用的主要空间驱动与表征



地图均裁剪到同一阿布扎比城市有效域；连续变量按城市像元分位数拉伸。

图 3 地形、夜光、道路、标签概率与 AlphaEarth PCA-RGB

图 3 展示了模型实际消费的主要驱动：

- 高程均值约 8.77 m，中位数约 4.66 m，城市有效域最大约 58.87 m；
- 坡度均值约 0.63°，最大约 20.61°；
- VIIRS 年度平均辐亮度均值由 2017 年约 55.24 增加到 2024 年约 65.06；
- OSM 主干路距离由 3,902 个主干道路要素栅格化后计算；全部道路要素共 103,687 个；
- AlphaEarth 在 2017–2024 每年覆盖 79,775/79,775 个城市 mask 像元，逐像元 L2 范数约为 1；
- 图中的 AlphaEarth PCA-RGB 只用于帮助观察 64 维嵌入的空间结构。2024 年前三主成分解释约 71.3% 方差，但颜色本身没有固定物理含义。

2.5 输入标签质量：有变化信号，也有明显噪声




图 4 Dynamic World 年度标签质量与变化回退诊断

数据审计结果为 PASS_WITH_LABEL_NOISE_WARNING，而不是无条件 PASS。主要证据如下：

- 2017–2024 平均有 54.97% 的城市像元年度平均最高类别概率低于 0.5；
- 该比例从 2017 年 51.0% 上升到 2024 年 61.3%；
- 相邻年度标签变化比例约为 3.0%–6.2%；
- 对发生年度变化的像元，隔年又回到原标签的比例中位数约为 36.11%；
- 但 AlphaEarth 变化像元的年际余弦相似度在全部七个年度转移中都低于稳定像元，差值约为 -0.0022 至 -0.0105，说明数据中仍然包含可学习的变化信号。

因此，本实验同时保留两个评价视角：

1. 全有效域结果：反映模型对实际发布年度产品的拟合能力；
2. 高置信度敏感性结果：只在起点和目标年度平均最高概率都不低于 0.5 的预冻结子集上评价。

后文会看到，三个模型在高置信度子集上的变化 FoM 都很低。这限制了“真实城市变化预测”的主张强度。

2.6 约束数据

ESA WorldCover 代理约束中，永久水体命中 23,331 个 100 m 像元，湿地或红树林命中 6,073 个像元。OSM 派生层中：

- 道路栅格像元：48,111；
- 主干路栅格像元：7,984；
- 保护区代理：1,210 像元；
- 机场/港口代理：4,203 像元。

叠加年度起点水体/湿地类别后，2022 起点硬排除 mask 为 28,831 像元，2024 起点为 28,942 像元。硬排除区内允许保持现状，不允许三个模型随意转换。

这些约束只能叫做公开数据代理约束。它们不能替代 Abu Dhabi Department of Municipalities and Transport、Abu Dhabi Spatial Data Infrastructure 或 Environment Agency – Abu Dhabi 的法定数据。

3. 三个模型实际看到了什么

三个模型不完全消费相同特征，但它们共享相同状态语义、空间范围、动作、约束和评价器。差异正是实验要比较的模型机制。

模型	训练期信息	空间机制	未来状态写回	需求处理
GeoSOS-FLUS	2021 完整土地覆盖；坐标、高程、坡度、VIIRS、道路与主干路距离	外部 FLUS 控制台 ANN 适宜性 + CA 竞争和邻域	每年 CA 输出作为下一年起点	FLUS 内部迭代逼近目标，允许小幅需求误差
Geospatial Kernel	2017→2018、2018→2019、2019→2020、2020→2021 转移；显式状态、3×3/7×7 邻域、地形、夜光、道路、坐标	HistGradientBoosting 学习类别适宜性，显式空间分配器按适宜性和邻域竞争分配	每年土地覆盖状态和邻域显式重算	共享可行需求分配器精确满足目标
Paper58	2017–2021 AlphaEarth 年度嵌入；2017–2021 标签训练六类语义解码器；历史需求向量	需求条件 Latent Dynamics Network 在 64 维潜状态中预测，再经语义解码和空间分配	潜状态与语义土地覆盖状态都逐年写回	共享可行需求分配器精确满足目标

3.1 GeoSOS-FLUS

本实验使用真实外部二进制：

/Users/zhouning/FLUS_console_crossplatform/build/cmake-release/flus_console

不是用自写 CA 冒充 FLUS。ANN 产生六类适宜性概率，CA 接收土地覆盖起点、概率、限制区、转换成本、邻域权重和目标像元数。FLUS 保留其原生迭代收敛特性，所以需求并不总能精确达到。

冻结成本矩阵禁止水体和湿地与其他类别相互转换，但没有事后增加“建成区不可逆”规则。这使规划实验中的 FLUS 出现既有建成退出与异地补建。由于规则在结果产生前已经冻结，本报告保留并公开这一行为，而不是看到结果后修改规则。

3.2 GWM Geospatial Kernel

Geospatial Kernel 的核心不是“看一张图直接猜下一张图”，而是显式实现：

1. 当前像元是什么类别；
2. 3×3 和 7×7 邻域中各种类别占多少；
3. 高程、坡度、夜光、道路距离和坐标如何影响类别适宜性；
4. 规划动作要求每一类最终需要多少像元；
5. 哪些像元被硬约束锁定；
6. 按学习到的适宜性和邻域连片倾向，将有限变化量分配到具体位置；
7. 将结果写回，重新计算下一年的邻域状态。

这是一种“显式状态 + 条件动作 + 空间传播”的有界世界模型内核。它不声称已经学会阿布扎比全部社会经济规律。

3.3 Paper58

Paper58 把 AlphaEarth 64 维年度嵌入看作潜状态。需求向量由六类目标占比与相对当前状态的六类增量组成。Latent Dynamics Network 接收当前潜状态和需求动作，预测下一潜状态；训练损失包括：

- 变化加权的潜状态余弦损失；
- 六类语义交叉熵；
- patch 级需求一致性；
- 硬约束位置的潜状态一致性。

模型只用 2017–2021 标签和嵌入训练，2022 用于验证，2023–2024 测试标签不参与拟合。规划时从真实 2024 AlphaEarth 潜状态起步，之后只递归写回预测潜状态，不读取未来遥感嵌入。

4. 统一实验协议

4.1 时间划分

阶段	年份	用途
历史拟合	2017→2018、2018→2019、 2019→2020、2020→2021	学习转移或潜状态动力学
验证	2021→2022	Paper58 模型选择与训练诊断
历史测试	2022→2023→2024	2022 起点两步开环，预测状态逐年写回，不读取 2023 观测写回
规划情景	2024→2025→...→2030	接收规划者给定的年度目标总量，未来外生显式驱动保持 2024 已知值

4.2 历史实验中的 oracle demand

历史实验使用目标年度真实类别总量作为“oracle demand”，目的是隔离空间分配能力：给定“每一类需要多少”，比较“模型把变化放在哪里”。这不是端到端预测未来类别总量。

测试分两步：

- 2023 预测从真实 2022 状态出发；
- 2024 预测从模型自己的 2023 预测状态出发，而不是从真实 2023 标签出发。

4.3 规划情景

三组情景是规划压力测试动作，不是通过历史趋势外推得到的“最可能未来”。

情景	每年建成区净增	每年低矮植被净增	到 2030 建成区净增	到 2030 绿地净增	含义
紧凑增长	500 像元 / 5 km ²	50 像元 / 0.5 km ²	3,000 像元 / 30 km ²	300 像元 / 3 km ²	中等增长，强调既有城市邻近分配
生态优先	350 像元 / 3.5 km ²	150 像元 / 1.5 km ²	2,100 像元 / 21 km ²	900 像元 / 9 km ²	较低建设增量、较高绿地增量
外延增长	1,000 像元 / 10 km ²	25 像元 / 0.25 km ²	6,000 像元 / 60 km ²	150 像元 / 1.5 km ²	高建设增量压力测试

水体和湿地总量锁定，所有目标总量先投影到与硬约束相容的可行需求。三个模型接收完全相同的年度可行目标。

4.4 评价指标

历史变化主指标为 Figure of Merit：

$$\text{FoM} = \frac{\text{hits}}{\text{hits} + \text{misses} + \text{false alarms}}$$

它只奖励正确命中的变化位置，并同时惩罚漏报和误报。总体准确率在“多数像元不变”的任务中容易显得很高，因此不能单独使用。

规划阶段不使用隐藏加权总分，而是公开以下目标分量并计算 Pareto 前沿：

- 需求总变差：预测类别总量与目标总量的差异；
- 生态转建成率：新增建成像元中，原始 2024 状态为木本/低矮植被/湿地的比例；
- 新增建成邻域紧凑度：新增建成像元 8 邻域中建成像元比例；
- 新增建成距主干路平均距离；
- 新增建成距 2024 既有建成区平均距离；
- 建成区和绿地净增；
- 硬约束违反；
- 既有建成退出像元，作为额外诊断项公开。

5. 历史模拟结果：2023 单步和 2024 两步开环

5.1 2024 地图结果




图 5 为三个随机种子的逐像元多数投票集成图。三模型均能保持水体、裸地和大面积既有建成区的主体空间格局，但新增建成区的具体位置和连片程度不同。

5.2 变化误差分解




图 6 将两步开环结果分为：稳定且正确、变化位置与类别均正确、命中变化位置但目标类别错误、漏报变化和误报变化。它比完整土地覆盖图更能显示模型差异。

- GeoSOS-FLUS 在城市中南部和东部有更多变化漏报，同时在部分既有城市边缘产生误报；
- Geospatial Kernel 在中南部新增建成区的变化命中更多，空间上更贴近已有建成区；
- Paper58 的 2024 两步结果产生最多变化命中，因此集成 change FoM 最高，但仍存在相当数量的漏报和误报。

5.3 三随机种子均值

年份	模型	change FoM	change F1	总体准确率	macro-F1	demand TV	高置信度 change FoM
2023	GeoSOS-FLUS	0.1283	0.2273	0.9183	0.8441	0.00283	0.0000
2023	Geospatial Kernel	0.2004	0.3338	0.9362	0.8499	0.00000	0.0114
2023	Paper58	0.1670	0.2862	0.9316	0.8457	0.00000	0.0000
2024	GeoSOS-FLUS	0.1815	0.3071	0.8595	0.7483	0.00538	0.0040
2024	Geospatial Kernel	0.2606	0.4134	0.8863	0.7670	0.00000	0.0118
2024	Paper58	0.2778	0.4348	0.8905	0.7693	0.00000	0.0188




图 7 历史模拟主要指标

表格和图 7 使用三随机种子均值；图 5、图 6 标题中的数值使用多数投票集成结果，因此两者会略有差异。

5.4 历史结果应该怎样解释

- 第一，Geospatial Kernel 是 2023 单步最强模型。其 change FoM 比外部 FLUS 高约 0.0721，说明显式状态、邻域和多年度转移学习对短期空间分配有价值。
- 第二，Paper58 是 2024 两步开环最强模型。其 change FoM 比 FLUS 高约 0.0963，也比 Geospatial Kernel 高约 0.0173。潜状态递归在第二步保留了更多有用变化信息。
- 第三，不能只看总体准确率。2024 年三个模型总体准确率仍有 0.86–0.89，但变化 FoM 只有 0.18–0.28。这说明“不变像元占多数”能够抬高总体准确率。
- 第四，必须保留标签噪声警告。高置信度子集变化 FoM 在 2024 年最高也只有 0.0188。当前证据支持“相对 Dynamic World 年度产品的条件分配能力”，尚不足以支持“已准确识别人类真实建设动作”。

6. 2025–2030 条件规划推演结果

6.1 2030 空间结果




图 8 三模型在三种规划情景下的 2030 空间分配

图 8 显示的是相对 2024 起点的变化：红色为新增建成区，绿色为新增植被，橙色为既有建成退出。每张图都是三个随机种子的多数投票集成结果。

视觉上可以直接看到：

- Geospatial Kernel 的新增建成区更多沿 2024 既有建成区边缘连续扩展；
- Paper58 也满足总量，但新增建成区更分散，与既有城市和主干路的平均距离更大；
- GeoSOS-FLUS 在三种情景下都出现大量橙色既有建成退出，同时在其他位置补建，形成明显空间周转。

6.2 2030 三随机种子均值

为保证宽表可读，表中 FLUS 指 GeoSOS-FLUS，GK 指 Geospatial Kernel，P58 指 Paper58。

模型	情景	demand TV	生态转建成率	紧凑度	距主干路 m	距既有建成区 m	建成净增	建成退出	绿地净增	Pareto
FLUS	紧凑增长	0.00044	1.74%	0.757	443.9	221.6	3,000	3,473	265	否
FLUS	生态优先	0.00404	1.79%	0.762	438.8	207.4	2,100	3,653	578	否
FLUS	外延增长	0.00033	1.38%	0.792	448.1	247.5	6,000	2,872	124	否
GK	紧凑增长	0.00000	0.00%	0.832	331.7	112.5	3,000	0	300	是
GK	生态优先	0.00000	0.00%	0.823	319.5	108.5	2,100	0	900	是
GK	外延增长	0.00000	0.00%	0.844	359.5	131.5	6,000	0	150	是
P58	紧凑增长	0.00000	0.00%	0.753	455.2	210.7	3,000	0	300	否
P58	生态优先	0.00000	0.00%	0.743	436.5	202.8	2,100	0	900	否
P58	外延增长	0.00000	0.00%	0.795	474.4	227.4	6,000	0	150	否




图 9 2030 规划结果的六项主要分量

6.3 Pareto 结果

当前冻结目标集合包含需求满足、生态转建成率、紧凑度、主干路距离、既有建成区距离、建成增量和绿地增量。没有使用隐藏的加权总分。

最终 Pareto 前沿为：

- 1. geospatial_kernel:compact；
- 2. geospatial_kernel:ecological_priority；

3. geospatial_kernel:outward_growth。

这不意味着三个 Geospatial Kernel 情景彼此等价。它们分别提供不同的建设与绿地收益：

- 生态优先情景绿地净增最大，新增建设量最小，同时主干路距离和既有建成区距离最低；
- 紧凑增长情景在建设增量和绿地增量之间居中；
- 外延增长情景提供最大建设增量，但主干路和既有建成区距离略高。

它们都没有被另一个候选方案在全部冻结目标上同时压倒，所以都留在 Pareto 前沿。

6.4 为什么规划赢家与历史赢家不同

2024 历史两步开环由 Paper58 获得最高 change FoM，但规划代理目标由 Geospatial Kernel 全面占优。这并不矛盾，原因是两类任务评价不同能力：

- 历史任务问“能否复现 Dynamic World 2024 的变化位置”；
- 规划任务问“在给定需求下，布局是否紧凑、邻近道路和既有建成区、少占生态并满足约束”。

Paper58 的潜状态动力学更擅长拟合历史遥感状态演化，但训练损失没有直接优化城市紧凑性和主干路距离。Geospatial Kernel 的显式邻域和适宜性机制天然偏向连续扩展，因此在当前规划代理目标上更强。

7. 三模型综合对比

维度	GeoSOS-FLUS	Geospatial Kernel	Paper58
方法定位	传统 ANN + CA 土地利用模拟基线	显式地理状态、动作、约束与空间传播内核	遥感基础表征上的需求条件潜状态动力学
真实实现	外部 FLUS 控制台	Python 显式实现	Paper58 LDN checkpoint + 语义解码
2023 单步 change FoM	0.1283	0.2004	0.1670
2024 两步 change FoM	0.1815	0.2606	0.2778
需求满足	原生迭代，存在小误差	精确	精确
递归状态	土地覆盖 CA 状态	显式土地覆盖和邻域	64 维潜状态 + 土地覆盖语义状态
规划空间紧凑性	中等	最高	较低
可解释性	中等；转换和 CA 参数可见	较高；特征、动作、约束和分配过程显式	较低；潜状态维度缺少逐维语义
当前最突出问题	需求不完全收敛；冻结规则下既有建成大量退出	高置信度真实变化证据仍弱；尚未跨城市验证	规划目标未进入训练；空间布局较分散

三者不是简单的“旧模型、好模型、坏模型”关系：

- FLUS 是成熟的传统空间分配基线，真实外部实现使比较具备参考意义；
- Geospatial Kernel 当前最适合做显式、可控、可解释的规划条件推演；
- Paper58 证明潜状态世界模型在多步历史演化上有潜力，但还需要把规划目标、约束和空间拓扑更深地融入潜状态训练。

8. 这项工作证明了什么价值

8.1 已经证明的价值

1. 统一实验是可执行的。三个机制不同的模型已经在同一真实城市、同一状态语义和同一动作契约下运行，而不是各自使用不可比的数据和指标。
2. Geospatial Kernel 不是空接口。它能够学习多年度转移、接收显式需求动作、执行硬约束、逐年写回状态并输出具体空间栅格。
3. 相对传统 FLUS 存在可测增益。Geospatial Kernel 在 2023、2024 全有效域 change FoM 均高于外部 FLUS，并在当前规划指标上生成更紧凑和更邻近既有建设的方案。
4. 潜状态路线不是多余的。Paper58 在 2024 两步开环达到最高历史 change FoM，说明 AlphaEarth 潜状态包含对多步变化有用的信息。

5. 审计链条完整。原始来源、聚合方式、文件哈希、数据质量、预测输出和约束违反都已机器可读记录。

8.2 尚未证明的价值

- 1. 尚未证明模型能够预测阿布扎比真实规划政策和开发商决策；
- 2. 尚未证明 Dynamic World 年度标签变化等于真实建设动作；
- 3. 尚未证明结果能够迁移到迪拜、上海、重庆或其他城市；
- 4. 尚未证明 Geospatial Kernel 在所有土地利用模型和所有指标上普遍领先；
- 5. 尚未证明当前公开生态和基础设施代理足以支持真实投资决策；
- 6. 尚未完成全部负控制和像元级配对统计推断。

9. 数据和方法局限

9.1 土地覆盖不等于土地用途

Dynamic World 能区分建成、裸地、水体和植被，但不能可靠区分住宅、商业、工业、公共设施，也不知道地块容积率、产权、审批状态和项目阶段。因此，当前结果是“土地覆盖空间分配”，不是法定城市用地规划。

9.2 没有观测到真正的动作

历史数据只包含年度状态，没有建设许可、拆迁、道路开通、基础设施投资和政策时点。模型学到的是状态转移相关性，而不是经过识别的政策因果效应。

9.3 标签噪声限制历史结论

年度标签平均置信度低，回退比例高。全有效域上的领先可能同时包含对产品标签结构的拟合。高置信度变化 FoM 很低，必须作为主结果旁边的敏感性警告，而不能隐藏。

9.4 规划需求不是预测

2025–2030 类别目标是人为设定的压力测试动作。它们回答“如果每年需要这些数量，模型会放在哪里”，不回答“阿布扎比实际会需要多少”。

9.5 公开约束不是法定约束

OSM 保护区、机场和港口数据只是公共代理。真实规划必须接入法定保护区、地块边界、权属、城市增长边界、基础设施容量和已批项目。

9.6 FLUS 的建成退出行为

当前冻结转换成本没有增加建成区不可逆规则，所以 FLUS 出现大量既有建成退出。它既揭示了当前 FLUS 配置的不足，也提醒后续正式论文必须预先冻结并完整公布转换矩阵，不能事后只保留有利配置。

9.7 规划目标仍是代理指标

主干路距离、既有建成区距离和紧凑度不等于真实基础设施成本。真实成本还取决于道路容量、轨道、供水、电力、排水、地价、土壤和项目时序。

10. 从公共基准走向真实运营还缺什么数据

需要的数据	可能的现实运营方	对模型的价值
法定城市边界、分区和地块	Abu Dhabi Department of Municipalities and Transport, AD-SDI	将 100 m 土地覆盖模型升级为地块级规划模型

需要的数据	可能的现实运营方	对模型的价值
建设许可、竣工和拆除事件	DMT、市政机构、开发审批系统	获得真实动作及动作时点，区分“变化相关性”和“建设行为”
法定保护区、红树林和生态监测	Environment Agency – Abu Dhabi	替换 ESA/OSM 公共代理，建立真实生态约束和影响评价
道路、公共交通和容量规划	Integrated Transport Centre / DMT	从简单距离代理升级到交通可达性和容量约束
水、电、排水和区域冷却容量	Department of Energy、公共事业运营方	计算真实新增基础设施成本和承载上限
人口、就业、住房和产业需求	Statistics Centre – Abu Dhabi、DMT	建立未来类别需求模型，而不是手工设定年度像元数
已批项目和开发商项目时序	政府项目台账及主要开发运营方	验证模型是否能在项目级别预测实际落位与建设节奏

如果只能取得公开遥感和 OSM，当前基准适合研究“条件空间分配”；如果能够取得审批、地块和基础设施数据，才有机会升级为可供运营方验证的“城市开发有界世界模型”。

11. 下一阶段应该怎样推进

11.1 先完成科学控制，而不是继续增加新场景

协议中以下控制仍待完成：

- state persistence；
- Markov-CA；
- action-deleted；
- action-shuffled；
- constraint-deleted；
- spatial-driver-shuffled。

这些控制用于回答：模型增益究竟来自真实动作条件、空间驱动和约束，还是仅仅来自类别惯性或需求后处理。

11.2 增加统计推断

应在冻结评价像元上运行模型间配对 bootstrap，报告 change FoM、change F1 和规划目标差异的置信区间。只有三个随机种子的均值不足以证明稳定优势。

11.3 引入权威数据后重新冻结 V2

如果获得法定数据，应建立独立的 abu-dhabi-land-use-v2，不能直接替换 V1 输入后继续沿用旧结果。V2 应预先冻结：

- 法定边界和地块；
- 允许转换矩阵，包括是否允许建成区退出；
- 真实建设事件；
- 规划约束和基础设施容量；
- 训练、验证、测试时间切分；
- 主要和次要评价指标。

11.4 对 Paper58 的直接改进

Paper58 下一步不应只增加训练 epoch，而应把规划目标显式引入：

- 邻域拓扑或图结构损失；
- 紧凑性和道路可达性条件；
- 约束可微投影；
- action-deleted / action-shuffled 消融；
- 潜状态不确定性与多样本 rollout。

11.5 对 Geospatial Kernel 的直接改进

Geospatial Kernel 下一步应重点验证，而不是继续扩张概念：

- 跨年份和跨空间分区的稳定性；
- Markov-CA、FLUS 和 persistence 的配对统计比较；
- 在权威动作数据上区分“条件分配”和“动作响应”；
- 将硬编码代理目标替换为运营方确认的约束和成本；
- 输出可审计的每个变化像元适宜性、动作贡献和约束来源。

12. 可复现性与产物

12.1 核心执行命令

```
cd /Users/zhouning/gisdataagent

# 历史模拟
.venv/bin/python benchmarks/abu_dhabi_land_use_v1/run_geosos_flus.py
.venv/bin/python benchmarks/abu_dhabi_land_use_v1/run_geospatial_kernel.py
.venv/bin/python ../paper58-geofm-world-model-rl/experiments/abu_dhabi/run_paper58_abu_dhabi.py
.venv/bin/python benchmarks/abu_dhabi_land_use_v1/compile_comparison.py

# 2025–2030 条件规划推演
.venv/bin/python benchmarks/abu_dhabi_land_use_v1/run_planning_scenarios.py
.venv/bin/python benchmarks/abu_dhabi_land_use_v1/compile_planning.py

# 图表与输出审计
.venv/bin/python benchmarks/abu_dhabi_land_use_v1/render_planning_map.py
.venv/bin/python benchmarks/abu_dhabi_land_use_v1/render_full_report_figures.py
.venv/bin/python benchmarks/abu_dhabi_land_use_v1/audit_outputs.py
```

12.2 关键机器可读文件

文件	内容
protocol.json	冻结城市、状态、动作、模型、切分、指标、控制和主张边界
grid_profile.json	CRS、分辨率、网格范围、面积和 mask 哈希
gee_input_manifest.json	34 个 GEE 输入文件、来源、年份、大小和 SHA-256
osm_input_manifest.json	Geofabrik PBF、道路和代理约束来源与哈希
data_audit.json	覆盖率、类别面积、置信度、变化、回退、AlphaEarth 和地形审计
comparison_report.json	历史三模型三种子、集成结果和模型间差值
planning_scenario_report.json	三模型 2025–2030 逐年情景输出记录
planning_comparison_report.json	规划指标、种子统计、集成指标和 Pareto 前沿
output_audit.json	240 张发布预测栅格的路径、SHA-256、网格和约束审计

12.3 验证状态

- 阿布扎比基准测试：9 passed；
- Paper58 需求条件测试：8 passed；
- 本次涉及 Python 文件：ruff 全部通过；
- 发布预测审计：PASS，240/240 有效，硬约束违反为 0；
- 域外非零像元：0；
- 当前协议状态：historical_and_planning_core_complete_required_controls_pending。

13. 最终结论

这次阿布扎比实验已经形成一个可以看、可以跑、可以审计的有界地理空间世界模型比较，而不是继续停留在抽象定义。

结论可以概括为三句话：

1. 历史短期分配：Geospatial Kernel 最强；历史两步开环：Paper58 最强；两者都高于当前外部 GeoSOS-FLUS。
2. 条件规划：在当前冻结的需求、约束和公共代理目标下，Geospatial Kernel 产生了更紧凑、更邻近主干路和既有建成区的方案，三个情景均进入 Pareto 前沿。
3. 科学边界：现有结果仍受 Dynamic World 标签波动、缺少真实动作、公开代理约束和单城市实验限制，不能表述为对阿布扎比真实未来的准确预测。

从 GWM 的角度，这项工作的现实意义不是制造一个无所不知的“城市世界”，而是建立一个状态可观测、动作可输入、约束可执行、结果可递归、误差可评价、边界可说明的城市土地覆盖实验世界。Geospatial Kernel 已经在这个有界世界内证明了实现价值；下一阶段的重点应是控制实验、统计推断和权威运营数据，而不是继续扩大“世界”的口号。