GIS因果推断展望

Prospects on Causal Inferences in GIS

摘要

Abstract

尽管因果推测在地理学研究中是传统方法，但在过去几十年可统计性以及可运算性的因果推断框架的开发对GIS的集成都非常有限。为促进空间因果分析，GIS应该开发新的数据模型以及软件工具以实现因果结构的发现以及因果效应的识别和估计。基于事件和基于场景的时空模型都是前沿的概念。具备空间特性的因果模型可以通过集成空间统计模型以及已有的用于因果分析的可运算性和可统计性模型。因果推断的定量方法存在一些限制；一个完整的因果分析应当包含定性分析。

关键词

Keywords

因果推断、潜在结果模型、因果图模型、空间统计、GIS

介绍

Introduction

因果推断被认为是过去50多年统计学发展中最重要的思想之一（Gelman & Vehtari,2021）【What are the most important statistical ideas of the past 50 year?】。2021年的诺贝尔经济学奖颁发给了Joshua Angrist和Guido Imbens“由于他们的方法对因果关系分析做出了贡献”。在这之前，2011年的图灵奖颁发给了Judea Pearl，由于他“通过对概率学以及因果推理开发了一种计算方法对人工智能的发展作出了基础性贡献”。然而，因果推理相关的所有重大进步对地理学领域的理论性和方法论的发展都只有有限的影响。尽管由于GIS在社会治理和管理中获得广泛的应用，统计性因果推断的进步也得以在地理信息科学领域实现，但对于严格的因果推断有着更高的要求。在当前的因果推断框架中集成空间特性给地理学以及地理信息科学带来了机会。这篇文章推测了在GIS的研发中的一些好的方向。尽管因果推断对于地理学和地理信息科学并不完全是个新事物，但基于可统计性和可计算性形式的空间因果分析仍然稀缺。在方法论以及技术层面，已经具备开发空间特性的因果推断模型的条件。

因果推断并不是新事物

Causal Inference Is Not New

人类一直都在努力发现他们身边以及自身发生的现象的原因，追求获得这些相关事件的规则与逻辑以及相互间的结果。将其中一些事件的发生归于上帝的超能力或者那些创造了世界运行规律的神明。科学家们则相信某个现象的发生是由一些规则控制的过程的结果。为了发现某个事件的原因或者获得某个结果需要揭示将它们串联在一起的规则与逻辑，或者基于经验和观察归纳出解释和结论。传统的演绎和归纳的推理在现代科学研究中仍存在。

尽管基于回归的统计学习是推理的一种当代的演绎模式，其一直被认为它的用途仅限于揭示相关性而并非结果与原因之间的因果性。回归模型通常基于建立相关性结论，量化估计不确定性，以及有时用于基于某种程度的准确性实现预测，但不善于进行因果推理。这样一种研究现状很难让人满意，尤其是对那些期望通过政策进行经济手段实现干预的经济学家，需要进行一种新的药物效果评估的生物医学科学家，或者是对那些以获得关于人与环境关系的知识为使命的地理学家。因果推断，或者是识别某个现象的原因以及判断当原因发生变化时对应的现象将发生什么，在近几十年来已经吸引了科学界大多数研究者进行了付出；尤其是，多个有影响力的理论框架已经建立，具体有潜在结果模型（Angrist et al.,1996）【Identification of causal effects using instrumental variables】（Fisher,1936）【Design of experiments】（Holland,1986）【Statistics and causal inference】（Imbens & Rubin,2010,2015）【Rubin causal

model】【Causal inference in statistics,social,and biomedical sciences】(Neyman,1923)【On the application of probability theory to agricultural experiments】(Rosenbaum & Rubin,1983)【The central role of the propensity score in observational studies for causal effects】(Rubin,1997)【Estimating causal effects from large data sets using propensity scores】以及因果图模型(Pearl & Mackenzie,2018)**【The book of why:The new science of cause and effect】**(Pearl,2009a)【Causal inference in statistics:An overview】。2011年图灵奖颁发给Pearl以及2021年诺贝尔经济学奖颁发给Angrist和Imbens以表彰他们为因果推断的贡献，同时也是对因果推断领域的研究以及应用的重大成果的认可。在统计学家看来，因果推断的发展已经被认为是统计学在过去50年最重要的成就之一。

当因果推断已经成为主流，在地理学和地理信息科学领域，其也不能被忽视。Mercer在上世纪70年代构建了房屋质量与社会经济因子之间的因果关系的回归模型，这是在地理学中使用统计因果推断的最早尝试之一(Mercer,1975)【Metropolitan housing quality and an application of causal modeling】。为了简单的评估一下学术范围内的地理学和地理信息科学的因果推断的情况，选择了一组期刊并且进行了一个两阶段的关键字搜索，“difference in differences”和“propensity score”，这两个是因果分析的关键方法。这些文章里或多或少都提及到了因果推断。如表1所示，在Mercer的文章之后的几十年里，在经济地理，区域科学以及流行病学领域有很多使用潜在结果框架进行因果分析。在这些选中的期刊中，集中在经济学以及流行病学并且有非常强的地理关联性，比如，城市经济学，区域以及城市经济学，和流行病学，在2000年以后提及因果推断的文章尤其多。在地理学期刊中，经济地理由于其与经济学强绑定而尤其突出。AAG年鉴，地理学中的顶级期刊，也开始接收基于可统计性或可计算性方法的因果关系的文章。这些刊物包含了大量的理论性，技术性以及应用主题，大多数关于潜在结果框架。同时，基于因果图的研究是稀缺的，除了流行病学。不需要深入这些综合文献的综述(Akbari et al.,2021)【Spatial causality:A systematic review on spatial causal inference】(Baum-Snow & Ferreira,2015)【Causal inference in urban and regional economics】(Reich et al.,2020)【A review of spatial causal inference methods for environmental and epidemiological applications】这些已经可提供关于地理学和相关学科中考虑因果推断的剪影。尽管相对于其姊妹学科，地理学也已经开始慢慢将因果推断整合到其方法论框架中，这充分说明地理学家已经开始重视因果推断相关的研究机会，表现为空间相关因果模型的发展(Kolak & Anselin,2020)【A spatial perspective on the econometrics of program evaluation】(Zhang et al.,2019)【Will the development of a high-speed railway have impacts on land use patterns in China?】。

Journals	"Difference in differences"	"Propensity score"
Economic Geography	33	23
Journal of Economic Geography	26	21
Urban Geography	5	3
Annals of AAG	7	3
Professional Geography	1	2
International Regional Science Review	7	14
Urban Economics	125	50
Regional and Urban Economics	200	73
Epidemiology	895	115
Geographical Analysis	5	2
Spatial Statistics	1	2
Geographical Systems	2	1
Computer Environment and Urban Systems	0	0
International Journal of GISci	0	0
Cartography and Geographic Information Science	0	1
Transactions in GIS	0	0
Remote Sensing of Environment	0	2

表1 地理学和相关学科的相关期刊中有关统计性因果推断关键字出现的频率

在GIS领域，基于场景建模，已经通过地理处理和模拟得以实践并且被应用于类似城市生长，土地利用变化以及环境管理等专题（Batty & Longley,1986）【The fractal simulation of urban structure】（Chen et al.,2020）【Global projections of future urban land expansion under shared socioeconomic pathways】（Li & Yeh,2000,2002）【Modelling sustainable urban development by the integration of connstrained cellular automata and GIS】【Neural-network-based cellular automata for simulating multiple land use changes using GIS】

（Swetnam et al.,2011）【Mapping socioeconomic scenarios of land cover change:A GIS method to enable ecosystem service modelling】（Torrens & Torrens,2004）【Geosimulation】，也可以被看作是一类因果推断。其尝试回答的问题是关于“what if”一个或多个因子的状态随着时间变化了，某些方面或者是整个系统可能会如何响应（Batty,2007）【Cities and complexity:Understanding cities with cellular automata,agent-based models,and fractals】。尽管因果推断的统计方法已经进入GIS的主流，因果推理仍然是其理论性和技术性传统方法之一。

空间统计因果推断是新事物
Spatial Statistical Causal Inference Is New
我们的关键字检索揭示了在地理信息科学有关因果推断的研究是严重欠缺的；大多数现有的在地理学领域有关因果性的文章都是近些年发表的。基于空间特性的因果推断研究仍处于其婴儿期。软件工具无法拿来即用，因此实现空间因果性学习需要通过编程整合不同的软件包。因果推断在普遍意义上为地理学研究尤其是地理信息科学提供了新的界限。（Carre & Handani,2021）【Pyramidal framework:guidance for the next generation of GIS spatial-temporal models】
对于统计性因果推断的所有三个子领域，地理学和地理信息科学都是新事物，比如，因果发现，因果识别以及因果效应估计（Tikka & Karvaene,2018）【Identifying causal effects with the R package causaleffect】。基于数据发现因果规则和结构已经是所有数据挖掘（Bhoopathi & Rama,2017）【Causal rule mining for knowledge discovery from database】（Silverstein et al.,2000）【Scalable techniques for mining causal structures】和空间数据挖掘（Bleisch et al.,2014）【Mining candidate causal relationships in movement patterns】（Galton et al.,2015）【Extracting causal rules from spatio-temporal data】（Yuan,1996）【Temporal GIS and spatio-temporal modeling】研究的一个热门领域。它们通常基于可运算性形式而不是被设计为适用于混杂效应并且不需要处理适用于统计模型的表示形式以及因果效应的估计。基于因果图模型（Glymour et al.,2019）【Review of causal discovery methods based on graphical models】（Pearl,2009b）【Causality:Models,reasoning and inference(2nd ed.)】的因果结构发现算法已经被广泛应用于地理空间研究，基于现有工具的应用却很少见（Ramsey et al.,2018）【TETRAD-A toolbox for causal discovery】，除了流行病学和公共卫生领域（Fleischer & Roux,2008）【Using directed acyclic graphs to guide analyses of neighbourhood health effects:An introduction】。
对于某个因果结构，其因果效应不是必须从观测中进行识别。Pearl建议使用do算子规则以及相应的算法去帮助解决识别问题（Peral,1995）【Causal diagrams for empirical research】（Shpitser & Pearl,2006）【Identification of joint interventional distributions in recursive semi-Markovian causal models】，其已经在R语言的“causaleffect”包（Tikka & Karvanen,2018）【Identifying causal effects with the R package causaleffect】中实现，通过提供了“DAGitty”，另一个基于图的因果推断工具可以被用于确定工具变量（Textor et al.,2016）【Robust causal inference using directed acyclic graphs:The R package ‘dagitty’】。因果发现相关的应用程序工具如TETRAD和MIM（Haughton et al.,2006）【A review of three directed acyclic graphs software packages:MIN,Tetrad,and WinMine】以及因果效应识别工具在地理学和地理信息科学中还很稀缺。此外，空间效应——不管直接的还是间接的——还没有被直接包含在这些算法中，留下了进一步细化的空间。
因果效应估计相关领域近些年在地理学研究中已经取得明显的进展。对于地理学家而言一个合适的领域是Stable Unit Treatment Value或者SUTVA假设，这是在反事实框架（Imbens & Rubin,2015）【Causal inference in statistics,social,and biomedical sciences】中进行干预效果估计的关键并且经常被空间依赖性和空间异质性所影响。（Kolak & Anselin,2020）【A spatial perspective on the econometrics of program evaluation】Kolak and Anselin最近提出的空间板

模型（Elhorst,2014）【Spatial panel data models】可以被扩展为在执行difference-in-differences分析时解决SUTVA假设，同时指出“在区域科学中对干预因果效应的估计仍处于初级阶段”，同时也映射了在估计因果效应时跨不同领域的方法的现状。

与**GIS**的关联

Relevance to GIS

GIS作为一个计算机软件系统可以对可计算性和可统计性因果推理的所有三个方面做出贡献，比如，因果结构发现，因果效应识别和估计。这里将聚焦在探索可运算性和软件相关方面：数据模型和数据库模型，数据处理函数，用于因果发现、识别和估计的核心函数。

数据模型是对真实世界系统的数字化表示，这决定了可运算的算法如何设计、实现并被高效运行（Fox et al.,1988）【Solving problems on concurrent processors】。传统的矢量栅格数据模型以及其扩展仍然在使用GIS解决地理空间问题时扮演重要的角色（Zeiler,1999）【Modeling our world:The ESRI guide to geodatabase design】。很难想象没有栅格或者不规则三角网数据模型如何去计算坡度，或者没有网络数据模型如何去发现最短路径。在GIS中实现用于进行统计性因果推断的工具需要新的数据模型，其可以在多层级、多维度以及多重表征上表达地理现象和过程。Yuan提出的基于事件的数据模型（Yuan,2020）【Why are events important and how to compute them in geospatial research?】，Lu等提出的基于场景的数据模型（Lu et al.,2019）【Reflections and speculations on the progress in GIS:A geographic perspective】，遗留系统仍在使用的NetCDF（Rew & Davis,1990）【An interface for scientific data access】，以及在过去几十年间提出的各种时空数据模型（Gong,1997）【An object oriented spatio temporal data model in GIS】（Yuan,1996）【Temporal GIS and spatio-temporal modeling】（Yuan et al.,2014）【Space-time representation and analytics】，为开发出可以包含空间统计因果推理的数据模型和数据库模型提供了理论和技术基础。

对于地理空间对象，其不但在地理空间上有关联，在时间上也需要正式的表达。空间权重矩阵和半变异函数是用于表示空间关系的两种常规形式，可通过时空权重矩阵扩展其时间维度以及时空协方差函数（时空克里金）（Cressie & Wikle,2015）【Statistics for spatio-temporal data】，在时空经济学中更普遍使用了传统面板数据模型（Elhorst,2014）【Spatial panel data models】。这些时空关系的可计算性表示是后续实现空间因果推断算法的基础。举个例子，一个合成变量可以通过特征向量空间过滤（ESF）方法生成，作为时空关系的一个代理，同时潜在的解决了空间因果推断中的关键问题。这里将简短地阐述这一点。

数据操作和处理可以确保来自多源和数据集和不同模型被集成并符合可运算性和可统计性的因果模型的需求。区域插值，举个例子，被普遍应用于在数据被采集为一种通用单元时来自不同空间单元的数据的降级和升级。当GIS空间插值函数已经从简单的基于平均权重的方法（Goodchild & Lam,1980）（Areal interpolation:A variant of the traditional spatial problem）进化到更严格的空间统计的形式以兼容高斯和计数数据（Krivorunchko et al.,2011）【Multivariate areal interpolation for continuous and count data】，仍有很多与非高斯数据相关的问题需要被解决（Comber & Zeng,2019）【Spatial interpolation using areal features:A review of methods and opportunities using new forms of data with coded illustrations】（De Oliveira,2014）【Poisson Kriging:A closer investigation】。最后，所有的区域插值算法必须遵从可修改的区域单元问题（MAUP）（Openshaw & Taylor,1979）【A million or so correlation coeddicients:Three experiments on the modifiable areal unit problem】以及其变种可修改的时间单元问题（MTUP）。当纵向数据需要被合并以执行因果分析时后者更有相关性（Cheng & Adepeju,2014）【Modifiable temporal unit problem(MTUP) and its effect on space-time cluster detection】。

如前面的章节所讨论，将空间组件与由Pearl提出的因果图框架进行整合的努力，在基于空间数据集之上发现因果规则和关系上已经少量但活跃的研究。因为地理要素可以同时影响原因因子和结果，控制地理的混杂效应应当是必要的。代替使用绝对的地理位置（球面或平面坐标），由来自空间权重矩阵的特征向量或时空权重矩阵的线性整合成的一种合成变量可被用于因果图模型，参与到因果结构发现和识别过程。

通过潜在结果框架进行因果推断的传统方法，比如匹配得分，工具变量以及**difference in differences**已经被假定与空间效应无关。已有有一些努力在填补这样的鸿沟。倾向得分匹配通过在逻辑回归中包含基于近似度的变量或者添加更多严格的空间概率模型以度量邻近效应以降低地理混杂因子（De Castris & Pellegrini,2015）【neighborhood effects on the propensity score matching】。工具变量分析使用地理区域或者特征空间向量过滤（ESF）生成的合成变量作为一个工具去缓解混杂效应（Le Gallo & Paez,2013）【Using synthetic variables in instrumental variable estimation of spatial series models】（Vertosick et al.,2017）【A systematic review of instrumental variable analyses using geographic region as an instrument】。Difference in differences分析可以使用空间板模型进行空间扩展（Kolak & Anselin,2020）【A spatial perspective on econometrics of program evaluation】。基于特征向量空间过滤（ESF）的方法具有基于现有的非空间模型维护同样的模型标准和估计的优势，尤其是对于对非高斯结果的建模（Griffith et al.,2019）【Spatial regression analysis using eigenvector spatial filtering】。这些空间特性的方法和模型的软件实现与主流因果推断模型大多以R语言包形式一样（Bivand et al.,2013）【Applied spatial data analysis with R(2nd ed.,2013 edition】（Millo et al.,2012）【splm:Spatial panel data models in R】（Murakami,2017）【spmoran:An R package for Moran’s eigenvector-based spatial regression analysis】（Rosseel,2012）【Lavaan:An R package for structural equation modeling and more】（Textor et al.,2016）【Robust causal inference using directed acyclic graphs:The R package ‘dagitty’】（Tikka & Karvanen,2018）【Identifying causal effects with the R package causaleffect】。将他们与商业GIS平台整合可以通过桥接APIs进行，比如特征向量空间过滤（ESF）工具，其通过将R函数与ArcGIS工具链接以执行高级空间回归模型（Koo et al.,2018）【Integrating spatial data analysis functionalities in a GIS environment:Spatial analysis using ArcGIS Engine and R（SAAR）】。

结论
Conclusions

作为一类学术研究的模式，因果推理是地理学以及地理信息科学中一种传统形式。作为理论和方法，统计性和可运算性的因果推断已经成为相关学科的研究和开发的主流。尤其是基于图的因果推断。今天，将地理学带入因果推断的时机已经成熟并且可以超越几何建模或者图形建模以及回归建模以提升GIS的能力。

同时，我们应该留意到定量方式的限制，尤其是本文中讨论的准实验框架。社会系统是复杂的，并且很多原因的因子可能是无法量化和度量的。当通过代理和组合变量去表示它们时，我们可能获得的因果效应是不准确的甚至是有误导性的（Berrie,2019）【Causal inference methods and simulation approaches in observational health resarch within a geographical framework】。此外，社会、经济以及政策等现象的因果结构是很难于量化的。最关键的是当前因果推断框架中的单向因果关系的假设，并不允许在因果变量之间存在双向的交互。最后，对于基于政治经济以及社会理论的定量的因果推理仍有很多实质性的批评（Poore & Chrisman,2006）【Order from noise:Toward a social theory of geographic informations】（Walters & Vayda,2009）【Event ecology,causal historical analysis,and human-environment research】，这就要求以一种整合了定量和定性的方式进行因果推理。